



TRABAJO PRÁCTICO N° 3

Carrera: Licenciatura en Sistemas
Ingeniería Informática

Temas: Fase de limpieza y preparación de Datos
Entrega: 7-09-2026

Enunciado

Se solicita que se desarrollen los siguientes conceptos teóricos y en los ejercicios prácticos en python.

Preguntas Teóricas

1. Desarrolle el concepto de Limpieza y transformación de datos en el proceso de extracción del conocimiento.
2. Explique el concepto de información faltante y la solución para los mismos.
3. ¿Qué es una matriz de correlación y para que sirve?
4. Explique el proceso de normalización de datos y cuando se utiliza.

Ejercicios Prácticos

Ejercicio 1

Descargue el dataset countries.csv que contiene la información de países del mundo. Desarrolle los siguientes items:

- a. Lea los datos de countries
- b. Analice la información básica del dataset. (Cantidad de registros, cantidad de variables, cuales son numéricas, cuales son variables categóricas)
- c. Tratamiento para los null. ¿Cuáles variables son numéricas, cuales son string? ¿Cuántas variables?
- d. Analice la dispersión de los datos y elija un método para unificarlos (escalamiento, normalización).

Ejercicio 2

Descargue el archivo de “reporte-vecino-hechos-delictual.xls” de la cátedra, utilice el software Rapidminer para desarrollar los siguientes ejercicios. Los datos responden a hechos delictuales ocurridos en la provincia. Los datos dados son importantes para hacer estudios de seguridad para ello es necesario limpiar los datos y dejarlos listos para hacer el análisis.

1. Para el atributo “modus_operandis”:
 - a. Realice un diagrama de barras y analice el estado en el que se encuentra del atributo “modus_operandis”.
 - b. Para ese atributo, homogenice los valores para obtener categorías únicas.
 - c. ¿Qué otros atributos necesita homogenizar?. Aplique el operador para los



atributos que sean necesarios.

2. Valores Faltantes
 - a. Realice exploración visual para ver cuál es el porcentaje de faltantes en cada atributo.
 - b. Para el atributo “edad.damnificado” reemplace los atributos faltantes. Elija el tipo de reemplazo que hará (min, max, promedio) y justifique el motivo de su elección.
 - c. ¿Para qué atributos considera necesario aplicar el operador?
3. Generación de Atributos
 - a. Considerando que ocurren una gran cantidad de hechos en la capital de la provincia es necesario distinguir cuales son de Capital y cuáles no. Genere un atributo que permita hacer esta distinción.
 - b. ¿Cuándo es conveniente generar atributos de un mismo dataset?
4. Discretización de los datos
 - a. Para el archivo discretice la edad del damnificado. Los rangos de edad deben ser acordes a la etapa de crecimiento (niño, adolescente, joven, etc).
 - b. ¿Considera que otro atributo necesite discretización?

Ejercicio 3

Seguimos trabajando con el dataset “diabetes.csv”. Donde, los datos responden a un grupo de mujeres que se les hizo los estudios correspondientes para saber si tienen diabetes o no.

1. Matriz de correlación
 - a. Realizar una matriz de correlación que permita identificar cuáles son los atributos que tienen más relación entre sí.
 - b. ¿Qué atributos tienen más relación con el objetivo?
2. Normalización de las variables
 - a. Analice la distribución de los datos e índice que atributos es necesario normalizarlos.
 - b. Normalice las variables necesarias
 - c. ¿Para qué nos serviría este proceso de normalización?
3. Discretice la edad de las pacientes.